

Já li o enunciado. É um projeto de Engenharia de Grandes Dados (EGD) onde têm de:

- Obter, processar e analisar um dataset com **Spark** (Dataproc/Colab/Local)
- Fazer **queries e/ou um pipeline de ML**
- Avaliar **performance com diferentes números de nós de computação**
- Entregar um **relatório de 6 páginas** com introdução, related work, dataset profiling, queries/ML, performance e análise de resultados
- Apresentar a **22/05/2026** e entregar até **29/05/2026** (tens ~1 semana até à apresentação)

Antes de te propor uma divisão concreta de tarefas, preciso de saber algumas coisas para fazer uma divisão que faça sentido: Boa, com essas respostas já consigo propor uma divisão concreta. Deixa-me começar por dois alertas importantes sobre as escolhas, e depois proponho a divisão.

Dois pontos de atenção antes de começarem

1. O ponto fraco da escolha "Local" é precisamente o requisito de "different number of computing nodes". Em Spark standalone local, têm essencialmente três opções para satisfazer este ponto, e convém escolherem já:

- *Mais simples*: variar paralelismo com `local[1]`, `local[2]`, `local[4]`, `local[8]`: mas isto são threads, não nós
- *Mais correto*: montar um Spark Standalone Cluster com vários workers na mesma máquina (ou em 2-3 portáteis dos membros do grupo na mesma rede)
- *Recomendado*: fazerem TUDO local, e usarem um dos \$300 de créditos gratuitos da Google só para a secção de performance, correndo o mesmo job em Dataproc com 1, 2 e 4 workers. Fica muito mais convincente no relatório

2. Porto + Lisboa = dataset relativamente pequeno (~30k listings no total). Para a parte de escalabilidade ficar interessante, considerem juntar também o `calendar.csv.gz` (que é grande, milhões de linhas com preço/disponibilidade dia-a-dia) e os `reviews.csv.gz`. Isso dá-vos volume real para benchmark.

Divisão do trabalho

Pensei na divisão de forma a equilibrar carga e a aproveitar o nível misto: coloquei tarefas mais técnicas para quem tem mais à-vontade com Spark e tarefas mais analíticas/de relatório para quem tem menos.

Pessoa 1: Data Engineering & Ingestão (*nível: intermédio*) Download dos datasets de Porto e Lisboa (listings, calendar, reviews, neighbourhoods do Inside Airbnb). Definir esquema unificado das duas cidades (acrescentar coluna `city`). Limpeza: tratar nulos, converter tipos (preços de string "\$1,234.00" → float, datas, booleanos), remover

duplicados, normalizar `room_type/property_type`. Output: DataFrames Spark limpos guardados em Parquet (mais eficiente para o resto do trabalho).

Pessoa 2: Dataset Profiling & EDA (*nível: iniciante/intermédio: bom para começar*)

Caracterização estatística do dataset: número de registos por cidade, distribuição de preços, ocupação, tipos de quarto, bairros, hosts (multi-listing vs single), distribuição geográfica. Gráficos descritivos (histogramas, boxplots, mapas com folium). Esta parte alimenta diretamente a secção "Dataset Profiling" do relatório.

Pessoa 3: Queries analíticas em Spark SQL (*nível: intermédio*) Definir e implementar 6-10 queries com valor analítico, comparando Porto e Lisboa. Exemplos:

- Top 10 bairros mais caros / mais baratos por cidade
- Sazonalidade de preços ao longo do ano (usar `calendar`)
- Taxa de ocupação média por tipo de propriedade
- "Super-hosts" vs hosts normais (preço médio, rating)
- Correlação entre preço e número de reviews/rating
- Comparação Porto vs Lisboa: preço médio, ocupação, tipo de oferta dominante

Pessoa 4: Pipeline de ML (*nível: intermédio*) Pipeline com Spark MLlib para **prever o preço de um listing** (regressão é o problema clássico nestes datasets e funciona bem). Etapas: feature engineering (one-hot para categoricals, scaling, lidar com texto/amenities), **Pipeline** do MLlib com `StringIndexer` + `VectorAssembler` + modelo (Linear Regression baseline + Random Forest ou GBT), train/test split, métricas (RMSE, MAE, R^2), comparação entre modelos. Alternativa mais leve: classificar `room_type` ou prever se um listing terá ocupação alta.

Pessoa 5: Performance / Benchmarking & Coordenação (*nível: iniciante/intermédio*)

Correr os jobs mais pesados (preferencialmente as queries da Pessoa 3 e o treino da Pessoa 4) com diferentes configurações: 1, 2, 4, 8 workers/cores. Medir tempos, calcular speedup e eficiência, fazer gráficos de scaling. Esta pessoa também coordena o relatório (juntar contribuições, garantir coerência, formatação, gestão das 6 páginas).

Distribuição do relatório (todos contribuem)

Secção	Responsável principal
Introdução	Pessoa 5 (com input de todos)
Related work	Pessoa 2
Dataset profiling	Pessoa 2
Queries	Pessoa 3
ML pipeline	Pessoa 4

Performance / scalability	Pessoa 5
Results analysis	Pessoa 3 + Pessoa 4
Apresentação (slides)	Pessoa 1 monta, todos apresentam

Cronograma sugerido (até 22/05: 8 dias)

- **Dias 1-2 (14-15/05):** Pessoa 1 entrega os Parquets limpos. Restantes começam a estudar a sua parte
- **Dias 3-5 (16-18/05):** Trabalho paralelo em queries, profiling, pipeline ML
- **Dia 6 (19/05):** Pessoa 5 começa benchmarks com o que estiver pronto
- **Dia 7 (20/05):** Integração + escrita do relatório
- **Dia 8 (21/05):** Slides + ensaio. Apresentação 22/05
- **Buffer:** 23-29/05 para polir o relatório final antes da entrega

Queres que crie isto num documento Word formatado para partilhares com o grupo? Posso também montar um esqueleto do repositório (estrutura de pastas + notebooks de partida) para arrancarem mais depressa.